



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(национальный исследовательский университет)»

Институт (Филиал) № 8 «Компьютерные науки и прикладная математика»

Образовательный центр 806

Группа М8О-214СВ-24 Направление подготовки 02.03.02 «Фундаментальная информатика и информационные технологии»

Магистерская программа Информатика

Квалификация: магистр

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА МАГИСТРА

На тему: Разработка и исследование пулов потоков с механизмом work-stealing на языке C++

Автор ВКРМ: _____ Спиридонов Кирилл Анатольевич (_____)

Научный руководитель: _____ (_____)

Консультант: _____ (_____)

Консультант: _____ (_____)

Рецензент: _____ (_____)

К защите допустить

Заведующий кафедрой № 806 _____ Крылов Сергей Сергеевич (_____)

____ мая 2026 года

Москва 2026

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	3
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	4
1 Анализ предметной области и обоснование темы исследования . . .	5
1.1 Актуальность проблемы параллельного выполнения задач в современных программных системах	5
1.1.1 Тенденции развития многоядерных и многопроцессорных архитектур	5
1.1.2 Проблемы наивного подхода к управлению потоками . . .	6
1.1.3 Накладные расходы на синхронизацию и балансировку нагрузки как нерешённая практическая проблема	8
1.1.4 Область применения: высоконагруженные серверы, системы реального времени и высокопроизводительные вычисления	10
1.2 Обзор существующих подходов и решений	13
1.2.1 Классические модели управления потоками	13
1.2.2 Механизм work-stealing: история возникновения и теоретические основы	14
1.2.3 Обзор научных и профессиональных публикаций	17
1.2.4 Анализ существующих реализаций пулов потоков	18
1.3 Цели, задачи и требования к разрабатываемому решению	22
1.3.1 Постановка цели исследования	22
1.3.2 Декомпозиция цели на конкретные задачи	23
2 Теоретическое обоснование и проектирование решения	25
2.1 Принципы и логическая модель решения	25
2.1.1 Модель многопоточных вычислений: работа, глубина, критический путь	25
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	29

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящей выпускной квалификационной работе магистра применяют следующие термины с соответствующими определениями:

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящей выпускной квалификационной работе магистра применяют следующие сокращения и обозначения:

1 Анализ предметной области и обоснование темы исследования

1.1 Актуальность проблемы параллельного выполнения задач в современных программных системах

1.1.1 Тенденции развития многоядерных и многопроцессорных архитектур

На протяжении нескольких десятилетий основным способом повышения производительности процессоров являлось увеличение тактовой частоты. Данная стратегия позволяла разработчикам программного обеспечения практически бесплатно получать прирост производительности при переходе на новое поколение оборудования. Однако в начале 2000-х годов этот подход столкнулся с фундаментальными физическими ограничениями: дальнейший рост тактовой частоты приводил к недопустимому увеличению тепловыделения и энергопотребления [1].

Ответом индустрии на данное ограничение стал переход к многоядерным архитектурам. Вместо наращивания производительности одного ядра производители начали размещать на одном кристалле несколько вычислительных ядер, каждое из которых работает на относительно невысокой тактовой частоте. Согласно данным компании Intel, уже к 2006 году большинство новых потребительских процессоров выпускалось с двумя и более ядрами, а к 2023 году флагманские серверные процессоры содержат сотни вычислительных ядер [2].

Данная тенденция нашла отражение в известном высказывании Херба Саттера, ставшем крылатой фразой в сообществе разработчиков: «Бесплатный обед закончился» [1]. Суть этого утверждения состоит в том, что простое обновление оборудования более не даёт автоматического прироста производительности для однопоточных программ. Вместо этого разработчики вынуждены явно проектировать свои приложения с расчётом на параллельное выполнение, чтобы задействовать все доступные вычислительные ресурсы.

Параллельно с развитием многоядерных процессоров активно развивались и многопроцессорные системы, в которых несколько физических процессоров объединяются в единую вычислительную платформу. Такие системы получили широкое распространение в области высокопроизводительных вычислений (HPC), центрах обработки данных и

серверных инфраструктурах крупных интернет-компаний. Архитектура NUMA (Non-Uniform Memory Access), характерная для многопроцессорных систем, вносит дополнительную сложность в разработку параллельных программ: время доступа к памяти зависит от того, на каком узле она физически расположена [3].

Таким образом, к середине 2010-х годов параллелизм превратился из узкоспециализированной темы, интересной лишь разработчикам суперкомпьютеров, в повседневную реальность для широкого круга инженеров-программистов. Веб-серверы, игровые движки, системы машинного обучения, базы данных и пользовательские приложения — все они вынуждены эффективно использовать параллелизм для достижения приемлемой производительности [4].

Рост числа ядер порождает принципиально новые требования к механизмам управления параллельным выполнением задач. Простые решения, приемлемые при двух-четырёх ядрах, демонстрируют неудовлетворительное масштабирование при 32, 64 и более ядрах. Именно поэтому исследование эффективных механизмов управления потоками и распределения задач между ними приобретает особую актуальность в современных условиях.

1.1.2 Проблемы наивного подхода к управлению потоками

Наиболее очевидным и простым подходом к параллельному выполнению задач является создание нового потока для каждой поступающей задачи и его уничтожение по завершении работы. Данный подход интуитивно понятен, прост в реализации и нередко используется в учебных примерах и прототипах. Однако при применении в производственных системах он обнаруживает ряд серьёзных недостатков.

Высокие накладные расходы на создание и уничтожение потоков. Создание потока операционной системой является дорогостоящей операцией. В операционной системе Linux создание потока через вызов `clone()` занимает порядка 5–15 мкс [5]. В операционной системе Windows аналогичная операция через `CreateThread()` имеет сопоставимую стоимость. При этом каждый поток требует выделения стека (как правило, от 64 КБ до 8 МБ по умолчанию), инициализации структур данных ядра и регистрации в планировщике операционной системы. Для

высоконагруженных систем, обрабатывающих тысячи и десятки тысяч задач в секунду, совокупные накладные расходы на управление жизненным циклом потоков могут составлять значительную долю общего времени выполнения [6].

Неконтролируемый рост числа потоков. В условиях пиковой нагрузки наивный подход приводит к лавинообразному росту числа одновременно существующих потоков. Поскольку каждый поток потребляет память (прежде всего под стек) и ресурсы ядра операционной системы, бесконтрольное создание потоков способно привести к исчерпанию памяти или достижению системного лимита на количество потоков. В Linux данный лимит определяется параметром ядра `/proc/sys/kernel/threads-max` и по умолчанию составляет порядка нескольких тысяч потоков. Превышение этого лимита влечёт отказ в создании новых потоков и, как следствие, отказ в обслуживании запросов [7].

Избыточное переключение контекста. Планировщик операционной системы распределяет процессорное время между всеми активными потоками посредством вытесняющей многозадачности. Переключение контекста — сохранение состояния текущего потока и восстановление состояния следующего — является затратной операцией, требующей нескольких микросекунд и приводящей к инвалидации кэшей процессора. Когда число активных потоков значительно превышает количество ядер, система тратит существенную долю времени на переключение контекстов вместо полезной работы [8]. Данный эффект получил название *thrashing* и является одной из ключевых проблем наивного подхода.

Отсутствие контроля над использованием ресурсов. Наивный подход не предоставляет механизмов ограничения количества одновременно выполняемых задач. В результате в периоды пиковой нагрузки система оказывается перегруженной, что негативно сказывается на латентности обработки всех запросов, включая приоритетные. Концепция *backpressure* — механизма обратного давления, при котором производитель задач замедляется при переполнении системы — принципиально несовместима с наивным подходом [9].

Неэффективное использование кэша процессора. Потоки, созданные для выполнения коротких задач, как правило, не имеют устойчивой привязки к конкретным ядрам процессора. Планировщик ОС может перемещать поток

между ядрами при каждом пробуждении, что приводит к систематическим промахам кэша и снижению эффективности работы с памятью. В современных процессорах разница в латентности между кэшем L1 и основной памятью достигает 200–300 раз, поэтому влияние данного фактора на производительность весьма существенно [10].

Перечисленные недостатки наивного подхода делают его непригодным для применения в производственных системах с высокими требованиями к производительности и предсказуемости. Это обстоятельство обусловило широкое распространение альтернативной концепции — пула потоков, при которой фиксированный набор заранее созданных потоков многократно используется для выполнения поступающих задач. Однако и в рамках концепции пула потоков остаётся ряд нерешённых проблем, связанных с балансировкой нагрузки между потоками, что будет рассмотрено в последующих разделах.

1.1.3 Накладные расходы на синхронизацию и балансировку нагрузки как нерешённая практическая проблема

Переход к многопоточному программированию неизбежно порождает необходимость координации доступа нескольких потоков к разделяемым ресурсам. Данная координация осуществляется посредством механизмов синхронизации, которые, при всей своей необходимости, сами по себе являются источником существенных накладных расходов и одной из наиболее трудноустраняемых практических проблем в области параллельного программирования [4].

Наиболее распространённым примитивом синхронизации является мьютекс (mutual exclusion lock). Операция захвата свободного мьютекса в Linux на архитектуре x86-64 посредством `pthread_mutex_lock()` занимает порядка 20–40 нс в отсутствие конкуренции. Однако при наличии конкуренции между потоками стоимость возрастает на порядки: поток, не сумевший захватить мьютекс, переводится в состояние ожидания, что влечёт системный вызов, переключение контекста и последующее пробуждение — совокупная стоимость данной цепочки может составлять 1–10 мкс [5]. В высоконагруженных системах, где потоки обращаются к разделяемым ресурсам тысячи раз в секунду, эти задержки накапливаются и становятся определяющим фактором производительности.

Проблема ложного разделения (false sharing). Кэш-память процессора работает с данными не побайтово, а блоками фиксированного размера — кэш-линиями, типичный размер которых составляет 64 байта. Если два потока, выполняющихся на разных ядрах, обращаются к различным переменным, но эти переменные расположены в одной кэш-линии, каждое обновление одной переменной инвалидирует кэш-линию на другом ядре. В результате возникают непроизводительные синхронизации кэша между ядрами, хотя с логической точки зрения потоки работают с независимыми данными [10]. Данное явление, называемое ложным разделением (false sharing), способно снизить производительность параллельной программы до уровня, сопоставимого с однопоточной реализацией или даже хуже неё.

Проблема АВА и сложность неблокирующих алгоритмов. В попытке избежать накладных расходов на блокирующую синхронизацию разработчики прибегают к неблокирующим (lock-free) алгоритмам, основанным на атомарных операциях процессора, в частности на инструкции compare-and-swap (CAS). Однако разработка корректных неблокирующих алгоритмов представляет значительную сложность. Классическим примером является проблема АВА: поток читает значение А, другой поток изменяет его на В, а затем обратно на А, после чего первый поток ошибочно считает, что данные не изменились [11]. Устранение подобных тонких ошибок требует глубокой экспертизы и существенно усложняет реализацию.

Эффективное распределение задач между потоками — балансировка нагрузки — является самостоятельной нетривиальной проблемой. В простейшей модели пула потоков с единой очередью задач все потоки конкурируют за одну разделяемую структуру данных. При большом числе потоков и высокой интенсивности поступления задач данная очередь превращается в узкое место: большую часть времени потоки проводят в ожидании доступа к ней, а не в выполнении полезной работы. Данный эффект получил название contention (конкуренция за ресурс) и является фундаментальным ограничением архитектуры с единой очередью [12].

Для устранения конкуренции применяются архитектуры с отдельными очередями задач для каждого потока. Однако данный подход порождает обратную проблему: при неравномерном поступлении задач одни потоки оказываются перегружены, тогда как другие простаивают в ожидании работы. Неравномерность нагрузки может быть обусловлена как характером

входящих запросов, так и различиями во времени выполнения отдельных задач. Задача оптимальной балансировки нагрузки в реальном времени без значительных накладных расходов на координацию остаётся актуальной научно-практической проблемой [13].

Ещё одной проблемой, связанной с синхронизацией, является инверсия приоритетов: высокоприоритетный поток вынужден ожидать освобождения ресурса, захваченного низкоприоритетным потоком, который, в свою очередь, вытеснен потоком со средним приоритетом. В результате высокоприоритетная задача блокируется на неопределённый срок. Данная проблема приобрела широкую известность после инцидента с марсоходом Mars Pathfinder в 1997 году, когда она привела к систематическим перезагрузкам бортового компьютера [14]. В современных системах реального времени инверсия приоритетов по-прежнему остаётся серьёзной угрозой корректности работы.

Совокупность перечисленных проблем — стоимость синхронизации, ложное разделение, сложность неблокирующих алгоритмов, конкуренция за очередь задач, неравномерность нагрузки и инверсия приоритетов — свидетельствует о том, что построение эффективного механизма управления параллельным выполнением задач является нетривиальной инженерной и исследовательской задачей, не имеющей универсального решения в рамках существующих подходов.

1.1.4 Область применения: высоконагруженные серверы, системы реального времени и высокопроизводительные вычисления

Проблемы эффективного параллельного выполнения задач актуальны для широкого спектра прикладных областей. Ниже рассматриваются наиболее значимые из них с точки зрения требований к механизмам управления потоками.

Современные веб-серверы и серверы приложений обрабатывают сотни тысяч и миллионы запросов в секунду. Такие компании, как Google, Facebook, Amazon и Яндекс, оперируют инфраструктурой, в которой каждый сервер должен поддерживать тысячи одновременных соединений при минимальной латентности отклика [15]. В данном контексте эффективный пул потоков является критически важным компонентом: он определяет пропускную способность сервера и характер деградации под нагрузкой. Неэффективная реализация приводит к резкому росту латентности при приближении к

пиковой нагрузке, что непосредственно влияет на пользовательский опыт и бизнес-показатели.

Характерной особенностью серверных нагрузок является их неоднородность: запросы существенно различаются по сложности и времени обработки, а интенсивность поступления запросов меняется во времени. Это делает статическое распределение задач между потоками неэффективным и требует динамической балансировки нагрузки [16].

Системы реального времени. В системах жёсткого и мягкого реального времени — бортовых авиационных системах, промышленных контроллерах, системах управления транспортными средствами — требования к предсказуемости временных характеристик особенно высоки. Здесь важна не только средняя производительность, но и гарантия того, что задача будет выполнена в пределах установленного временного дедлайна в наихудшем случае (Worst-Case Execution Time, WCET) [17].

Стандартные реализации пулов потоков общего назначения, как правило, не дают подобных гарантий: время ожидания задачи в очереди может варьироваться в широких пределах в зависимости от текущей загрузки системы. Разработка механизмов управления потоками с детерминированными временными характеристиками остаётся открытой исследовательской задачей [18].

Высокопроизводительные вычисления (HPC). В области HPC параллельные вычисления являются основным инструментом решения задач, недоступных для последовательных алгоритмов: молекулярного моделирования, климатических симуляций, задач вычислительной гидродинамики и обучения нейронных сетей [19]. Здесь на первый план выходит эффективность использования вычислительных ресурсов: простой даже небольшой части ядер суперкомпьютера обходится весьма дорого как в денежном, так и во временном отношении.

В HPC-приложениях широко применяется модель разделения задач «разделяй и властвуй» (divide and conquer): крупная задача рекурсивно разбивается на подзадачи вплоть до достижения базового случая. Данная модель естественным образом порождает древовидную структуру зависимостей, в которой динамически создаётся большое количество мелких задач. Именно для данного сценария механизм work-stealing демонстрирует наилучшие теоретические и практические результаты, что будет подробно

рассмотрено в следующем разделе [12].

Таким образом, перечисленные области применения объединяет общая потребность в эффективном, масштабируемом и предсказуемом механизме параллельного выполнения задач. Различия в требованиях — максимальная пропускная способность для серверных систем, предсказуемость латентности для игровых движков, детерминизм для систем реального времени и эффективность использования ресурсов для НРС — определяют многообразие подходов к реализации пулов потоков и обуславливают актуальность их исследования.

1.2 Обзор существующих подходов и решений

1.2.1 Классические модели управления потоками

В процессе развития параллельного программирования сложилось несколько устойчивых моделей управления потоками, каждая из которых представляет собой определённый компромисс между простотой реализации, накладными расходами и эффективностью использования ресурсов.

Исторически первой и наиболее простой является модель «поток на задачу» (thread-per-task), при которой для каждой входящей задачи создаётся отдельный поток, уничтожаемый по завершении работы. Достоинством данной модели является концептуальная простота: разработчику не требуется явно управлять жизненным циклом потоков или координировать распределение задач. Недостатки этой модели — высокие накладные расходы на создание и уничтожение потоков.

Следующим шагом в развитии стала модель пула потоков с единой глобальной очередью (single global queue thread pool). В данной модели при запуске приложения создаётся фиксированное число потоков, равное, как правило, числу логических ядер процессора. Все потоки разделяют одну очередь задач: производитель помещает задачи в конец очереди, а потоки-потребители извлекают их из начала. Данная модель устраняет накладные расходы на создание и уничтожение потоков, однако порождает новую проблему: разделяемая очередь становится точкой конкуренции. При большом числе потоков операции постановки и извлечения задач требуют синхронизации посредством мьютекса или атомарных операций, что ограничивает масштабируемость системы [20].

Для устранения конкуренции за единую очередь была предложена модель пула потоков с локальными очередями (per-thread queue thread pool). В данной архитектуре каждый поток владеет собственной очередью задач. Новые задачи назначаются потокам по некоторому правилу — например, по принципу Round Robin или путём хеширования идентификатора задачи. Данный подход снижает конкуренцию, однако приводит к статическому распределению задач, которое не адаптируется к реальной загрузке потоков. В результате возможна ситуация, когда одни потоки перегружены, тогда как другие простаивают [4].

Попыткой совместить преимущества обеих моделей стала архитектура с

иерархическими очередями (hierarchical queue). В ней глобальная очередь выступает резервуаром задач, а каждый поток дополнительно располагает локальным буфером для хранения небольшого числа задач. Поток в первую очередь берёт задачи из локального буфера, обращаясь к глобальной очереди лишь при его опустошении. Данный подход снижает частоту синхронизации, но не решает проблему неравномерной загрузки потоков [20].

Отдельного рассмотрения заслуживает модель реакторов (reactor pattern) и её расширение — модель SEDA (Staged Event-Driven Architecture). В модели реактора единственный поток обрабатывает события ввода-вывода и диспетчеризирует задачи, что позволяет избежать накладных расходов на синхронизацию, однако не позволяет эффективно задействовать несколько ядер. Модель SEDA разделяет обработку на несколько последовательных стадий, каждая из которых обслуживается собственным пулом потоков, что обеспечивает лучшую масштабируемость и управляемость нагрузки [16].

Анализ перечисленных моделей позволяет выявить фундаментальное противоречие, характерное для классических подходов: снижение конкуренции за разделяемые структуры данных достигается ценой ухудшения балансировки нагрузки, и наоборот. Данное противоречие является основной мотивацией для разработки механизма work-stealing, который стремится одновременно минимизировать синхронизацию и обеспечить динамическую балансировку нагрузки.

1.2.2 Механизм work-stealing: история возникновения и теоретические основы

Механизм work-stealing (кража задач) представляет собой алгоритм динамического распределения задач между потоками, при котором незагруженный поток вправе забирать («красть») задачи из очередей других, более загруженных потоков. Данный подход позволяет совместить низкую конкуренцию за локальные очереди с автоматической балансировкой нагрузки, не требующей централизованного координатора.

Истоки механизма work-stealing восходят к исследованиям в области параллельных вычислений, проводившимся в 1980-е годы. Одной из первых систем, реализовавших схожие принципы, стал язык Multilisp, разработанный Робертом Хэлстедом в Массачусетском технологическом институте в 1985 году [21]. В Multilisp параллельные вычисления организовывались

посредством конструкции `rcall`, а распределение задач между процессорами осуществлялось динамически.

Однако подлинной теоретической основой современного work-stealing стала система Cilk, разработанная в MIT в 1990-е годы группой под руководством Чарльза Лейзерсона. В основополагающей работе Блюмофе и Лейзерсона [12] была формализована модель многопоточных вычислений и доказана оптимальность жадного алгоритма work-stealing с точки зрения теоретической эффективности.

В модели Блюмофе и Лейзерсона многопоточное вычисление представляется в виде ориентированного ациклического графа (DAG), вершины которого соответствуют элементарным инструкциям, а рёбра задают отношения зависимости. Для данной модели вводятся два ключевых параметра: работа T_1 — суммарное число инструкций при выполнении на одном процессоре, и *глубина* (критический путь) T_∞ — длина наидлиннейшей цепочки зависимых инструкций.

Авторы доказали, что при выполнении на P процессорах алгоритм work-stealing обеспечивает время выполнения:

$$T_P \leq \frac{T_1}{P} + O(T_\infty) \quad (1)$$

Данная оценка является оптимальной с точностью до константного множителя: первое слагаемое отражает теоретический минимум, обусловленный объёмом работы, второе — неустранимые потери из-за последовательных зависимостей [12].

Помимо оценки времени выполнения, Блюмофе и Лейзерсон доказали, что алгоритм work-stealing является оптимальным по использованию памяти: потребление памяти при выполнении на P процессорах не превышает P -кратного потребления при последовательном выполнении. Данное свойство принципиально важно для практических приложений, поскольку бесконтрольный рост потребления памяти является типичной проблемой наивных реализаций параллельных вычислений.

Ключевым структурным элементом алгоритма work-stealing является двусторонняя очередь (double-ended queue, deque), которой владеет каждый поток. Работа с данной структурой данных подчиняется следующим правилам:

- поток-владелец помещает новые задачи в нижний конец очереди (push) и извлекает задачи для выполнения также из нижнего конца (pop), то есть работает по принципу стека (LIFO);
- поток-«вор», не имеющий собственных задач, извлекает задачи из верхнего конца очереди жертвы (steal), то есть работает по принципу очереди (FIFO).

Такое асимметричное использование deque преследует две цели. Во-первых, доступ владельца к нижнему концу в большинстве случаев не требует синхронизации, поскольку конкуренция возможна лишь в граничной ситуации, когда очередь содержит ровно одну задачу. Во-вторых, вору забирают задачи с верхнего конца, то есть наиболее «старые» задачи, порождённые ранее всего. В рекурсивных алгоритмах типа «разделяй и властвуй» такие задачи, как правило, являются наиболее крупными и предоставляют больше всего работы, что делает кражу максимально эффективной [13].

Важным практическим достижением стала работа Чейза и Лева [22], в которой была предложена реализация deque для work-stealing на основе динамически расширяемого кольцевого буфера. Данная реализация требует синхронизации (посредством инструкции CAS) лишь в случае конкуренции между владельцем и вором за последнюю задачу в очереди, обеспечивая тем самым практически неблокирующее поведение в типичных сценариях.

После публикации теоретических работ механизм work-stealing был реализован в ряде промышленных систем и языков программирования. Библиотека Intel Threading Building Blocks (TBB), выпущенная в 2006 году, стала одной из первых широко используемых реализаций work-stealing для языка C++ [12]. В языке Java механизм work-stealing был включён в стандартную библиотеку в виде класса ForkJoinPool, появившегося в версии Java 7 в 2011 году. В языке C++ стандарт не предоставляет встроенной реализации work-stealing, что обуславливает актуальность разработки собственных эффективных реализаций [20].

Таким образом, механизм work-stealing сочетает в себе строгое теоретическое обоснование и практическую эффективность, что делает его одним из наиболее перспективных подходов к управлению задачами в параллельных системах.

1.2.3 Обзор научных и профессиональных публикаций

Тематика параллельного программирования и управления потоками получила широкое освещение как в академической литературе, так и в профессиональных технических изданиях. Ниже представлен обзор ключевых работ, формирующих теоретическую и практическую основу настоящего исследования.

Фундаментальной теоретической работой в области work-stealing является статья Блюмофе и Лейзерсона «Scheduling Multithreaded Computations by Work Stealing» [12]. В данной работе авторы формализовали модель многопоточных вычислений на основе ориентированных ациклических графов и доказали, что жадный алгоритм work-stealing обеспечивает оптимальное время выполнения и оптимальное потребление памяти. Результаты этой работы по сей день остаются теоретическим фундаментом для всех практических реализаций механизма кражи задач.

Важное практическое дополнение к теории Блюмофе и Лейзерсона внесли Акер, Блеллох и Блюмофе в работе «The Data Locality of Work Stealing» [13]. Авторы исследовали влияние алгоритма work-stealing на локальность данных в кэш-памяти процессора и показали, что механизм кражи задач обеспечивает хорошую локальность при рекурсивных вычислениях типа «разделяй и властвуй». В частности, было установлено, что поток-владелец, работающий по принципу LIFO, повторно использует данные, недавно помещённые в кэш, тогда как воры, забирающие крупные задачи с верхнего конца очереди, не нарушают эту локальность.

Значительный вклад в практическую реализацию work-stealing внесли Чейз и Лев в работе «Dynamic Circular Work-Stealing Deque» [22]. Авторы предложили реализацию двусторонней очереди на основе динамически расширяемого кольцевого буфера, которая требует синхронизации лишь в редком граничном случае конкуренции за последний элемент. Данная структура данных легла в основу многих промышленных реализаций work-stealing, в том числе в библиотеке Intel TBB.

С точки зрения практики параллельного программирования на языке C++ наиболее полным и авторитетным руководством является книга Энтони Уильямса «C++ Concurrency in Action» [20]. Автор подробно рассматривает средства многопоточности, появившиеся в стандарте C++11 и развитые в

C++14 и C++17: примитивы синхронизации (`std::mutex`, `std::condition_variable`), атомарные операции (`std::atomic`), асинхронное выполнение (`std::future`, `std::async`), а также приводит пример реализации пула потоков с `work-stealing` на основе данных примитивов. Книга Уильямса служит основной методической базой настоящей работы.

Проблематика синхронизации и неблокирующих алгоритмов детально рассмотрена в книге Херлихи и соавторов «The Art of Multiprocessor Programming» [4]. Авторы систематически излагают теорию конкурентных структур данных, доказывают корректность неблокирующих алгоритмов и анализируют их производительность. Особую ценность представляют разделы, посвящённые формальным моделям корректности (линеаризуемости и последовательной согласованности), которые позволяют строго обосновать правильность реализаций `concurrent deque`.

Вопросы операционной поддержки многопоточности рассмотрены в работах Дреппера [5; 10]. В работе «The Native POSIX Thread Library for Linux» описана архитектура библиотеки NPTL, реализующей потоки POSIX в Linux, и анализируются накладные расходы на основные операции. В работе «What Every Programmer Should Know About Memory» детально исследуется влияние иерархии памяти на производительность многопоточных программ, в том числе эффекты ложного разделения и оптимальные стратегии размещения данных в кэш-памяти.

Таким образом, рассмотренные работы охватывают как теоретические основы механизма `work-stealing`, так и практические аспекты его реализации на языке C++. Совокупность данных публикаций формирует достаточную методическую базу для проведения настоящего исследования.

1.2.4 Анализ существующих реализаций пулов потоков

Для обоснования целесообразности разработки собственной реализации пула потоков с механизмом `work-stealing` необходимо проанализировать существующие решения. Ниже рассматриваются наиболее значимые реализации, а также стандартные средства многопоточности языка C++, доступные в стандартах до C++20.

Стандартные средства многопоточности C++ (до C++20). Стандарт C++11 ввёл в язык первую полноценную модель памяти для многопоточных

программ и набор примитивов для работы с потоками [20]. Класс `std::thread` обеспечивает создание и управление потоками операционной системы. Для синхронизации доступны `std::mutex` и его варианты, `std::condition_variable`, а также атомарные типы `std::atomic<T>`. Для асинхронного выполнения задач предусмотрены `std::future`, `std::promise` и функция `std::async`.

Вместе с тем стандартная библиотека C++ (вплоть до C++17 включительно) не предоставляет готовой реализации пула потоков. Функция `std::async` является ближайшим аналогом, однако её поведение существенно ограничено: стандарт не гарантирует повторного использования потоков, а реализация вправе выполнить задачу синхронно [20]. Таким образом, `std::async` не является надёжным инструментом для построения высокопроизводительных параллельных систем и не обеспечивает никакой балансировки нагрузки.

Intel Threading Building Blocks (oneTBB). Библиотека Intel TBB является одной из наиболее зрелых и широко используемых реализаций параллельных вычислений для C++. Она предоставляет высокоуровневые параллельные алгоритмы (`parallel_for`, `parallel_reduce`), конкурентные контейнеры и планировщик задач, основанный на механизме `work-stealing` [12]. Планировщик TBB автоматически определяет число рабочих потоков и управляет их загрузкой.

Ключевым достоинством TBB является высокая производительность и тщательная оптимизация под архитектуры Intel. Среди недостатков следует отметить значительный объём библиотеки, сложность внутреннего устройства, затрудняющую изучение и модификацию, а также историческую привязку к экосистеме Intel, хотя в настоящее время библиотека распространяется как открытый проект oneTBB.

Microsoft Parallel Patterns Library (PPL). Библиотека PPL входит в состав среды разработки Microsoft Visual Studio и предоставляет модель параллельного программирования, концептуально схожую с Intel TBB. PPL включает параллельные алгоритмы (`parallel_for`, `parallel_invoke`), класс `task` для асинхронного выполнения и планировщик `task_scheduler`, также реализующий `work-stealing`.

Существенным ограничением PPL является её привязанность к платформе Windows и среде Visual Studio, что делает невозможным

применение данной библиотеки в кроссплатформенных проектах. Кроме того, в отличие от TBV, PPL не является открытым программным обеспечением, что исключает возможность изучения и модификации её внутреннего устройства.

Пример реализации из книги «C++ Concurrency in Action». Энтони Уильямс в своей книге [20] приводит поэтапную разработку пула потоков с *work-stealing*, построенного исключительно на стандартных средствах C++11/14. Реализация основана на классе `std::thread` для управления рабочими потоками, `std::atomic` для неблокирующей синхронизации и шаблонном классе `work_stealing_queue`, реализующем двустороннюю очередь. Каждый рабочий поток владеет локальной очередью и при её опустошении пытается похитить задачу из очереди случайно выбранного потока.

Данная реализация имеет прежде всего образовательную ценность: она демонстрирует применение стандартных примитивов C++ для построения нетривиальных параллельных структур. Вместе с тем она не претендует на производительность промышленных библиотек и не содержит ряда оптимизаций, характерных для TBV, — в частности, адаптивного управления числом потоков и оптимизации под конкретную иерархию памяти.

Сравнительный анализ рассмотренных реализаций позволяет выявить их ключевые достоинства и недостатки. Существующие решения можно условно разделить на две группы.

Первую группу составляют промышленные библиотеки — Intel TBV и Microsoft PPL. Обе реализуют механизм *work-stealing* и обеспечивают высокую производительность благодаря многолетней оптимизации. Однако Intel TBV представляет собой крупную внешнюю зависимость со сложным внутренним устройством, затрудняющим изучение и модификацию. Microsoft PPL дополнительно ограничена платформой Windows и средой Visual Studio, что исключает её применение в кроссплатформенных проектах. Ни одна из этих библиотек не предоставляет возможности гибкой настройки планировщика под конкретный сценарий нагрузки без глубокого погружения во внутреннее устройство.

Вторую группу образуют стандартные средства C++ и учебные реализации. Функция `std::async`, введённая в стандарте C++11, не имеет внешних зависимостей и доступна на любой платформе, однако не реализует

механизм work-stealing, не гарантирует повторного использования потоков и не предоставляет никаких средств управления балансировкой нагрузки [20]. Реализация пула потоков с work-stealing, приведённая Уильямсом [20], построена исключительно на стандартных примитивах C++11/14, не имеет зависимостей и допускает полный контроль над внутренним устройством. Вместе с тем она носит прежде всего образовательный характер и не содержит оптимизаций, характерных для промышленных библиотек.

Таким образом, в настоящее время отсутствует реализация, которая одновременно удовлетворяла бы следующим требованиям: основана исключительно на стандарте C++11/14, не имеет внешних зависимостей, реализует механизм work-stealing и допускает систематическое исследование влияния параметров на производительность. Разработка такой реализации и её экспериментальное исследование составляют цель настоящей работы.

1.3 Цели, задачи и требования к разрабатываемому решению

1.3.1 Постановка цели исследования

Анализ предметной области, проведённый в разделах 1.1 и 1.2, позволяет сформулировать основное противоречие, определяющее актуальность настоящей работы. С одной стороны, механизм work-stealing обладает строгим теоретическим обоснованием и демонстрирует высокую эффективность в промышленных реализациях. С другой стороны, существующие промышленные реализации (Intel TBB, Microsoft PPL) представляют собой крупные библиотеки со сложным внутренним устройством, не допускающим лёгкой модификации и систематического исследования. Стандартная библиотека C++ (вплоть до C++17) не предоставляет готового пула потоков с механизмом work-stealing, а учебные реализации не подкреплены экспериментальными данными о производительности.

В связи с изложенным целью настоящей выпускной квалификационной работы является разработка библиотеки на языке C++, реализующей пул потоков с механизмом work-stealing, и экспериментальное исследование её производительности в сравнении с классическим пулом потоков при различных сценариях нагрузки.

Поставленная цель предполагает решение как инженерной, так и исследовательской задачи. Инженерная составляющая состоит в проектировании и реализации библиотеки, построенной исключительно на стандартных средствах языка C++ версий C++11/14/17, без внешних зависимостей. Исследовательская составляющая состоит в проведении серии измерений производительности, позволяющих количественно оценить преимущества и ограничения механизма work-stealing при различных условиях применения.

Выбор стандартов C++11/14/17 в качестве технологической основы обусловлен тремя соображениями. Во-первых, все необходимые примитивы многопоточности — `std::thread`, `std::atomic`, `std::mutex`, `std::condition_variable`, `std::future` — были введены в стандарте C++11 и в полной мере доступны начиная с этой версии языка. Во-вторых, стандарты C++11/14/17 по-прежнему остаются основными в большинстве

производственных кодовых баз, что обеспечивает широкую применимость разрабатываемой библиотеки. В-третьих, основная методическая база настоящей работы — книга Уильямса «C++ Concurrency in Action» [20] — рассматривает многопоточность именно в контексте данных стандартов, что обеспечивает строгое соответствие между теоретической основой и практической реализацией.

1.3.2 Декомпозиция цели на конкретные задачи

Для достижения поставленной цели необходимо решить следующие задачи.

Первая задача — анализ существующих подходов и решений. Провести систематический обзор теоретических работ по механизму `work-stealing`, классических моделей управления потоками и существующих реализаций пулов потоков. Выявить достоинства и недостатки существующих решений, обосновать требования к разрабатываемой библиотеке. Данная задача решается в главе 1 настоящей работы.

Вторая задача — проектирование архитектуры библиотеки. Разработать архитектуру библиотеки, включающую две реализации пула потоков: классический пул потоков с единой глобальной очередью задач и пул потоков с механизмом `work-stealing`. Спроектировать единый программный интерфейс, позволяющий использовать обе реализации взаимозаменяемо и проводить их сравнительное исследование в одинаковых условиях.

Третья задача — реализация неблокирующей двусторонней очереди. Разработать и реализовать структуру данных — двустороннюю очередь (`deque`) для механизма `work-stealing`, основанную на атомарных операциях `std::atomic`. Реализация должна обеспечивать неблокирующий доступ владельца очереди и корректную синхронизацию при краже задач сторонними потоками.

Четвёртая задача — реализация пулов потоков. На основе спроектированной архитектуры реализовать классический пул потоков с глобальной очередью и пул потоков с механизмом `work-stealing`. Обе реализации должны быть построены исключительно на стандартных средствах C++11/14/17 и не иметь внешних зависимостей.

Пятая задача — тестирование корректности. Разработать набор тестов, верифицирующих корректность работы реализованных структур данных и

пулов потоков. Тестирование должно охватывать граничные случаи: одновременный доступ к очереди владельца и вора, поведение при пустой очереди, корректность завершения работы пула при наличии незавершённых задач.

Шестая задача — экспериментальное исследование производительности. Разработать методику и набор тестов производительности (benchmarks), позволяющих сравнить классический пул потоков и пул потоков с work-stealing при различных сценариях нагрузки. Исследовать зависимость производительности от числа рабочих потоков, размера и характера задач. На основе полученных данных сформулировать выводы об условиях эффективного применения механизма work-stealing.

Седьмая задача — разработка документации и рекомендаций. Подготовить документацию к разработанной библиотеке и сформулировать практические рекомендации по её применению на основе результатов экспериментального исследования.

В ходе анализа предметной области и обзора существующих решений были получены следующие выводы.

Во-первых, переход к многоядерным архитектурам сделал параллелизм неотъемлемым требованием к современному программному обеспечению. Классические подходы к управлению потоками — модель «поток на задачу» и пул потоков с единой глобальной очередью — обнаруживают существенные ограничения с точки зрения масштабируемости и эффективности балансировки нагрузки при большом числе ядер.

Во-вторых, механизм work-stealing обладает строгим теоретическим обоснованием и доказанной оптимальностью по времени выполнения и потреблению памяти. Вместе с тем существующие промышленные реализации (Intel TBB, Microsoft PPL) не допускают лёгкого изучения и модификации, а стандартная библиотека C++ не предоставляет готовой реализации пула потоков с work-stealing.

В-третьих, сформулированные цель и задачи работы однозначно определяют её границы и критерии успеха: разработать библиотеку на чистом C++11/14/17 без внешних зависимостей, реализующую обе модели пула потоков с единым интерфейсом, и провести их сравнительное экспериментальное исследование.

2 Теоретическое обоснование и проектирование решения

2.1 Принципы и логическая модель решения

2.1.1 Модель многопоточных вычислений: работа, глубина, критический путь

Для теоретического обоснования эффективности механизма work-stealing необходима формальная модель, позволяющая описывать параллельные вычисления и рассуждать об их производительности независимо от конкретной реализации. В данном разделе излагается модель, предложенная Блюмофе и Лейзерсоном [12] и ставшая стандартной теоретической основой для анализа параллельных планировщиков задач.

В модели Блюмофе и Лейзерсона параллельное вычисление представляется в виде ориентированного ациклического графа $G = (V, E)$, где множество вершин V соответствует элементарным вычислительным шагам (инструкциям или задачам), а множество рёбер E задаёт отношения зависимости между ними: ребро $(u, v) \in E$ означает, что задача v не может начать выполнение до завершения задачи u .

Граф вычислений обладает единственной начальной вершиной (исток), соответствующей точке входа в параллельную программу, и единственной конечной вершиной (сток), соответствующей точке её завершения. Вершины, не связанные отношением зависимости, могут выполняться параллельно на различных процессорах. Таким образом, граф G полностью описывает структуру параллелизма вычисления: он определяет, какие задачи могут выполняться одновременно, а какие должны выполняться последовательно.

Рассмотрим в качестве иллюстрации алгоритм параллельного вычисления суммы массива методом «разделяй и властвуй». Массив рекурсивно делится пополам, левая и правая половины суммируются параллельно, после чего результаты складываются. Соответствующий граф вычислений имеет древовидную структуру: каждый внутренний узел соответствует операции сложения двух частичных сумм, а листья — суммированию отдельных элементов. Рёбра графа направлены от листьев к корню, отражая зависимость каждой операции сложения от результатов нижележащих задач.

На основе графа G вводятся два ключевых параметра, определяющих теоретические пределы производительности параллельного вычисления [12].

Работа T_1 — суммарное время выполнения всех вершин графа при использовании одного процессора, то есть длина оптимального последовательного выполнения:

$$T_1 = \sum_{v \in V} w(v), \quad (2)$$

где $w(v)$ — время выполнения задачи v . Работа представляет собой нижнюю оценку суммарного объёма вычислений, который необходимо выполнить независимо от числа процессоров.

Глубина (критический путь) T_∞ — длина наидлиннейшего пути в графе G от истока до стока при неограниченном числе процессоров:

$$T_\infty = \max_{p \in \text{paths}(G)} \sum_{v \in p} w(v), \quad (3)$$

где максимум берётся по всем путям p от истока до стока. Глубина определяет нижнюю оценку времени выполнения вычисления, которую невозможно преодолеть никаким числом процессоров: задачи, лежащие на критическом пути, вынуждены выполняться последовательно в силу отношений зависимости.

Параметры T_1 и T_∞ задают два нижних предела для времени выполнения T_P вычисления на P процессорах [12]:

$$T_P \geq \frac{T_1}{P}, \quad T_P \geq T_\infty. \quad (4)$$

Первое неравенство отражает тот факт, что P процессоров не могут выполнить работу T_1 быстрее, чем за T_1/P . Второе неравенство утверждает, что никакой планировщик не может выполнить вычисление быстрее, чем длина критического пути.

Блюмофе и Лейзерсон доказали, что жадный алгоритм work-stealing обеспечивает время выполнения, близкое к теоретическому минимуму [12]. А именно, при выполнении вычисления с работой T_1 и глубиной T_∞ на P процессорах планировщик work-stealing гарантирует:

$$T_P \leq \frac{T_1}{P} + O(T_\infty). \quad (5)$$

Данная оценка является оптимальной с точностью до константного множителя: первое слагаемое соответствует нижней оценке, обусловленной объёмом работы, второе — нижней оценке, обусловленной глубиной вычисления. Важно отметить, что данная гарантия обеспечивается без какой-либо информации о структуре графа вычислений: планировщик принимает решения о распределении задач динамически, исключительно на основе текущего состояния очередей потоков.

Для количественной оценки эффективности параллельного выполнения вводится понятие ускорения (speedup) — отношения времени последовательного выполнения к времени параллельного выполнения на P процессорах [4]:

$$S_P = \frac{T_1}{T_P}. \quad (6)$$

Идеальным (линейным) ускорением называется случай $S_P = P$, когда использование P процессоров даёт ровно P -кратное ускорение. На практике достичь линейного ускорения невозможно из-за наличия последовательных участков вычисления, накладных расходов на синхронизацию и эффектов иерархии памяти.

Фундаментальное ограничение на достижимое ускорение устанавливает закон Амдала [23]. Пусть доля последовательной части вычисления (то есть части, которая не может быть распараллелена) составляет $\alpha \in [0, 1]$. Тогда максимальное ускорение при использовании P процессоров ограничено сверху:

$$S_P \leq \frac{1}{\alpha + \frac{1-\alpha}{P}}. \quad (7)$$

При $P \rightarrow \infty$ данное выражение стремится к $1/\alpha$, то есть максимальное ускорение ограничено величиной, обратной доле последовательной части. Так, если 10% вычисления является последовательным ($\alpha = 0,1$), то максимально достижимое ускорение не превышает 10 независимо от числа процессоров.

Закон Амдала подчёркивает значимость минимизации последовательных участков в параллельных программах. Именно поэтому накладные расходы на синхронизацию, неизбежно возникающие при использовании разделяемых структур данных, столь критичны для производительности: каждый момент ожидания блокировки фактически увеличивает последовательную долю вычисления и тем самым ограничивает достижимое ускорение.

В контексте разрабатываемой библиотеки закон Амдала определяет ключевое требование к реализации: накладные расходы на управление очередями задач и механизм кражи должны быть минимизированы, чтобы не увеличивать эффективную долю последовательной части вычисления. Именно это требование обуславливает использование атомарных операций вместо блокирующей синхронизации в реализации двусторонней очереди.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Sutter H. The Free Lunch Is Over: A Fundamental Turn Toward Concurrency in Software // Dr. Dobbs's Journal. — 2005. — Т. 30, № 3. — С. 202—210.
2. Intel Corporation. Intel® Xeon® Scalable Processors. — 2023. — URL: <https://www.intel.com/content/www/us/en/products/details/processors/xeon/scalable.html> (дата обращения 01.11.2025).
3. Lameter C. NUMA (Non-Uniform Memory Access): An Overview // ACM Queue. — 2013. — Т. 11, № 7. — С. 40—51. — DOI: 10.1145/2508834.2513149.
4. The Art of Multiprocessor Programming / М. Herlihy [и др.]. — 2-е изд. — Cambridge, MA : Morgan Kaufmann, 2020.
5. Drepper U., Molnar I. The Native POSIX Thread Library for Linux. — Red Hat Inc., 2005.
6. Butenhof D. R. Programming with POSIX Threads. — Boston, MA : Addison-Wesley, 1997.
7. Love R. Linux Kernel Development. — 3-е изд. — Boston, MA : Addison-Wesley, 2010.
8. Tanenbaum A. S., Bos H. Modern Operating Systems. — 4-е изд. — Hoboken, NJ : Pearson, 2014.
9. Reactive Streams Working Group. Reactive Streams Specification. — 2014. — URL: <https://www.reactive-streams.org> (дата обращения 07.12.2025).
10. Drepper U. What Every Programmer Should Know About Memory. — Red Hat Inc., 2007.
11. Michael M. M., Scott M. L. Simple, Fast, and Practical Non-Blocking and Blocking Concurrent Queue Algorithms // Proceedings of the 15th Annual ACM Symposium on Principles of Distributed Computing. — 1996. — С. 267—275. — DOI: 10.1145/248052.248106.
12. Blumofe R. D., Leiserson C. E. Scheduling Multithreaded Computations by Work Stealing // Journal of the ACM. — 1999. — Т. 46, № 5. — С. 720—748. — DOI: 10.1145/324133.324234.

13. Acar U. A., Blelloch G. E., Blumofe R. D. The Data Locality of Work Stealing // Proceedings of the 12th Annual ACM Symposium on Parallel Algorithms and Architectures. — 2000. — С. 1—12. — DOI: 10.1145/341800.341801.
14. Reeves G. E. What Really Happened on Mars? // IEEE Spectrum. — 1998. — Т. 35, № 2. — С. 18—25.
15. Wiggins A. The Twelve-Factor App. — 2012. — URL: <https://12factor.net> (дата обращения 15.12.2025).
16. Welsh M., Culler D., Brewer E. SEDA: An Architecture for Well-Conditioned, Scalable Internet Services // ACM SIGOPS Operating Systems Review. — 2001. — Т. 35, № 5. — С. 230—243. — DOI: 10.1145/502059.502057.
17. The Worst-Case Execution-Time Problem — Overview of Methods and Survey of Tools / R. Wilhelm, J. Engblom, A. Ermedahl [и др.] // ACM Transactions on Embedded Computing Systems. — 2008. — Т. 7, № 3. — С. 1—53. — DOI: 10.1145/1347375.1347389.
18. An EDF Scheduling Class for the Linux Kernel / D. Faggioli [и др.] // Proceedings of the 11th Real-Time Linux Workshop. — 2009. — С. 1—10.
19. Dongarra J., Heroux M. A., Luszczek P. High-Performance Conjugate-Gradient Benchmark: A New Metric for Ranking High-Performance Computing Systems // The International Journal of High Performance Computing Applications. — 2016. — Т. 30, № 1. — С. 3—10. — DOI: 10.1177/1094342015593158.
20. Williams A. C++ Concurrency in Action. — 2-е изд. — Shelter Island, NY : Manning Publications, 2019.
21. Halstead R. H. Multilisp: A Language for Concurrent Symbolic Computation // ACM Transactions on Programming Languages and Systems. — 1985. — Т. 7, № 4. — С. 501—538. — DOI: 10.1145/4472.4478.
22. Chase D., Lev Y. Dynamic Circular Work-Stealing Deque // Proceedings of the 17th Annual ACM Symposium on Parallelism in Algorithms and Architectures. — 2005. — С. 21—28. — DOI: 10.1145/1073970.1073974.

23. Amdahl G. M. Validity of the Single Processor Approach to Achieving Large Scale Computing Capabilities // Proceedings of the April 18–20, 1967, Spring Joint Computer Conference. — 1967. — C. 483—485. — DOI: 10.1145/1465482.1465560.